

Spor Analitiği — Açık Futbol Lig İstatistikleri

Veri Bilimi Dönem Projesi — Kısa Rapor

Hazırlayanlar: Efe Ünlü (1306240091) · Mert Kurthasan (1306240033)

1. Problem Tanımı

Futbol, sonucu çok sayıda faktöre bağlı olan ve görece az gol içeren bir spordur; bu nedenle maç içi istatistiklerin (şut, isabetli şut, korner, faul, kart, ilk yarı skoru) sonucu ne ölçüde yansıttığı sık tartışılan bir konudur. Bazı istatistikler (örneğin toplam şut) sezgisel olarak üstünlükle ilişkilendirilse de, bu ilişkinin yönü ve gücü çoğu zaman varsayıldığı kadar net değildir. Bu proje, İngiltere Premier Lig'in dört sezonuna ait açık maç verilerini kullanarak bu ilişkileri nicel olarak inceler.

Çalışma iki tamamlayıcı amaç güder: (1) Betimsel analiz ile ev sahibi avantajının ve maç içi istatistiklerin sonuçla ilişkisinin veriyile ortaya konması; (2) Modelleme ile maç içi istatistik farklarından maç sonucunu (Ev galibiyeti H / Beraberlik D / Deplasman galibiyeti A) tahmin eden basit ve yorumlanabilir bir sınıflandırma modelinin kurulması. Yorumlanabilirlik bilinçli bir tercihtir: amaç yüksek doğruluklu bir tahmin motoru kurmak değil, hangi oyun dinamiklerinin sonuçla ilişkili olduğunu anlaşılır biçimde göstermektir.

Bu çerçevede üç araştırma sorusu tanımlanmıştır: (S1) Ev sahibi avantajı istatistiksel olarak gözlemlenebilir mi ve sezonlara göre değişir mi? (S2) Hangi maç içi istatistik, gol farkıyla (maç üstünlüğü) en güçlü ilişkilidir? (S3) İlk yarıyı önde kapatmak maç sonucunu ne ölçüde belirler?


2. Kullanılan Veri Seti ve Kaynağı

Veri seti: İngiltere Premier Lig maç istatistikleri, 2020-21 → 2023-24 sezonları. Kaynak: datahub.io üzerindeki GitHub deposu **datasets/football-datasets**; veriler orijinal olarak football-data.co.uk sitesinden derlenmektedir ve günlük olarak güncellenmektedir. Lisans: Open Data Commons Public Domain Dedication and License (PDDL) v1.0 — veri, atıf zorunluluğu olmaksızın serbestçe kullanılabilir. Boyut: her sezon 380 maç olmak üzere 4 dosya, toplam 1520 maç ve maç başına 22 sütun.

Her satır bir maçı temsil eder. Temel sütunlar şunlardır: FTHG/FTAG (maç sonu ev/deplasman gol), FTR (sonuç: H/D/A), HTHG/HTAG ve HTR (ilk yarı gol ve sonucu), HS/AS (toplam şut), HST/AST (isabetli şut), HC/AC (korner), HF/AF (faul), HY/AY (sarı kart), HR/AR (kırmızı kart). Verinin genel görünümü Tablo 1'de özetlenmiştir; maçların büyük çoğunluğunda gol sayısı düşüktür ve dağılım sağa çarpıktır (Şekil 1).

İstatistik	Ev golü	Dep. golü	İsabetli şut (ev)	Korner (ev)	Sarı kart (ev)
Ortalama	1.58	1.34	4.89	5.73	1.66
Std. sapma	1.37	1.25	2.67	3.10	1.27
En yüksek	9	8	15	17	6

Tablo 1. Seçili sütunlar için temel tanımlayıcı istatistikler (1520 maç).



Şekil 1. Maç başına toplam gol dağılımı (ortalama ≈ 2.91 gol/maç).

3. Yöntem

3.1 Veri Temizleme

Dört sezon dosyası ayrı ayrı okunup her birine bir **Season** sütunu eklendikten sonra tek bir tabloda birleştirildi. Tip dönüşümü: tarih sütunu metinden tarih tipine, gol/şut/korner/faul/kart sütunları tam sayıya çevrildi. Aykırı değer: ev sahibi toplam şut (HS) sütunu hem IQR (24 maç) hem Z-score ($|z|>3$) yöntemiyle incelendi; en yüksek değer 36 şuttur. Bu maçlar gerçek ve hatasız olduğundan veriden çıkarılmadı; yalnızca dağılımın uzun kuyruklu olduğu not edildi. Veriyi keyfi biçimde budamak yerine doğasını korumak tercih edildi.

Eksik veri senaryosu. Veri setinde gerçekte eksik değer ve yinelenen satır bulunmadı. Buna rağmen, gerçek projelerde sık karşılaşılan eksik veriyi ele alma yetkinliğini göstermek için verinin bir kopyasında iki sütuna yapay olarak %6–10 oranında eksik değer üretildi; bu eksikler önce tespit edilip görselleştirildi, ardından üç yöntemle (ortalama, medyan, KNN) dolduruldu. Gerçek değerler saklandığından yöntemler RMSE (hata) ile karşılaştırıldı: ilişkili sütunlardan (şut/korner) yararlanan KNN en düşük hatayı verdi ($RMSE \approx 2.09$; ortalama/medyan ≈ 2.57). Asıl veri tam olduğundan ana analiz tam veriyle sürdürüldü.

3.2 Özellik Türetme

Analizi ve modellemeyi kolaylaştırmak için fark temelli sütunlar türetildi: isabetli şut farkı (SoTDiff = HST – AST), toplam şut farkı, korner farkı, faul farkı, sarı ve kırmızı kart farkları ile ilk yarı gol farkı (HTGoalDiff). Fark değişkenleri, iki takımın göreceli üstünlüğünü tek bir sayıda topladığı için hem korelasyon analizi hem de doğrusal model için daha yorumlanabilir bir temsil sağlar.

3.3 Keşifsel Analiz ve Modelleme


EDA aşamasında temel istatistikler çıkarıldı ve beş farklı görselleştirme türü (histogram, çubuk grafik, kutu grafik, saçılım grafiği, ısı haritası) kullanıldı. Modelleme: maç sonucu (FTR) üç sınıflı hedef olarak alındı. Özellikler yalnızca maç içi istatistik farklarıdır; maç sonu gol sayıları (FTHG/FTAG) sonucu doğrudan tanımladığı için bilinçli olarak özellik kümesine dahil edilmedi — aksi halde model 'kopya çekmiş' olurdu. Veri, sınıf oranları korunarak %80 eğitim / %20 test olarak bölündü; özellikler standardize edildi (ortalama 0, standart sapma 1) ve bir Lojistik Regresyon modeli eğitildi. Performans, 'her zaman en sık sınıfı (ev galibiyeti) tahmin et' biçimindeki naif bir taban çizgisiyle karşılaştırıldı.

Neden makine öğrenmesi? Araştırma sorularında değişkenler tek tek incelenir; makine öğrenmesi ise tüm maç içi istatistikleri aynı anda değerlendirerek sonucun ne kadar açıklanabildiğini nesnel ve test edilebilir biçimde (taban çizgisine karşı doğruluk) ölçer. Bölme, ölçekleme, model ve değerlendirme adımlarının tamamı, bu bileşenleri hazır sunan **scikit-learn** kütüphanesiyle gerçekleştirilmiştir.

4. Bulgular

4.1 (S1) Ev Sahibi Avantajı

Dört sezonun tamamında maçların %43.8'i ev sahibi galibiyeti, %33.8'i deplasman galibiyeti ve %22.4'ü beraberlikle sonuçlandı. Ev sahipleri maç başına ortalama 1.58 gol atarken deplasman takımları 1.34 gol attı (Şekil 2). Bu üstünlüğün rastlantı olmadığını doğrulamak için kesin sonuçlu (beraberlik olmayan) 1180 maç üzerinde bir binom testi uygulandı (H_0 : ev sahibinin kazanma olasılığı = 0.5). Ev sahibi bu maçların %56.4'ünü kazanmıştır ve fark istatistiksel olarak anlamlıdır ($p \approx 1.1 \times 10^{-5} < 0.05$); yani ev sahibi avantajı hem betimsel hem çıkarımsal olarak doğrulanır.



Şekil 2. Tüm sezonlar için maç sonucu dağılımı.

Ancak sezon kırılımı önemli bir nüans ortaya koyar (Tablo 2): 2020-21 sezonunda ev sahibi galibiyeti (%37.9), deplasman galibiyetinin (%40.3) altında kalmıştır. Bu, ev avantajının kaybolduğu tek sezondur ve maçların pandemi nedeniyle büyük ölçüde seyircisiz oynandığı döneme denk gelir. Sonraki seyircili sezonlarda ev avantajı yeniden belirginleşmiştir (ev galibiyeti %43–48). Bu bulgu, ev sahibi avantajının bir bileşeninin taraftar etkisi olduğu yönündeki literatürle tutarlıdır ve bağlamın istatistikleri nasıl değiştirebildiğini gösterir.


Sezon	Maç	Ev gal. %	Berabere %	Dep. gal. %	Gol/maç
2020-21	380	37.9	21.8	40.3	2.69
2021-22	380	42.9	23.2	33.9	2.82
2022-23	380	48.4	22.9	28.7	2.85
2023-24	380	46.1	21.6	32.4	3.28
Genel	1520	43.8	22.4	33.8	2.91

Tablo 2. Sezonlara göre sonuç dağılımı ve maç başına gol. 2020-21 (seyircisiz) sezona dikkat.


4.2 (S2) Belirleyici İstatistik

Gol farkı (maç üstünlüğü) ile maç içi istatistik farkları arasındaki korelasyonlar incelendiğinde (Şekil 3), ilk yarı gol farkından ($r \approx 0.71$) sonra en güçlü ilişki isabetli şut farkındadır ($r \approx 0.66$). Toplam şut farkının ilişkisi belirgin şekilde daha zayıftır ($r \approx 0.42$); yani şutun kalitesi (isabet), miktarından daha belirleyicidir. Korner farkının ilişkisi zayıftır ($r \approx 0.15$), çünkü çok korner kullanmak çoğunlukla baskı kurmayı değil net gol fırsatına çevirememeyi de yansıtabilir.

Dikkat çekici biçimde, kartların gol farkıyla ilişkisi negatiftir (sarı $r \approx -0.16$, kırmızı $r \approx -0.17$). Bu, kartın bir 'üstünlük nedeni' değil, çoğunlukla geride veya baskı altında olmanın bir sonucu olduğunu düşündürür — korelasyonun nedensellik anlamına gelmediğinin somut bir örneğidir. Sonuca göre isabetli şut farkının dağılımı (Şekil 4) bu ilişkiyi görsel olarak da doğrular: ev sahibi kazandığında fark belirgin biçimde pozitifte kayar.



Şekil 3. Türetilmiş değişkenler arası korelasyon matrisi.



Şekil 4. Maç sonucuna göre isabetli şut farkının (ev – deplasman) dağılımı.

4.3 (S3) İlk Yarı Üstünlüğü

İlk yarı sonucu (HTR) ile maç sonu sonucu (FTR) arasındaki koşullu olasılıklar (Tablo 3) ilk yarı üstünlüğünün güçlü bir belirleyici olduğunu gösterir. İlk yarıyı önde kapatan ev sahibi takımlar maçların %78.2'sini, ilk yarıyı önde kapatan deplasman takımları ise %72.7'sini kazanmıştır. İlk yarıyı berabere kapatan maçlarda sonuç yine ev sahibi lehine eğilimlidir (%36.5'e karşı %30.7), bu da ikinci yarıda dahi ev sahibi avantajının sürdüğünü gösterir.

İlk yarı \ Maç sonu	Ev galibiyeti (H)	Beraberlik (D)	Dep. galibiyeti (A)
Ev önde (H)	78.2	14.8	7.0
Berabere (D)	36.5	32.8	30.7
Dep. önde (A)	10.9	16.4	72.7


Tablo 3. İlk yarı sonucuna göre maç sonu olasılıkları (satır yüzdesi, %).

4.4 Model Sonuçları

Lojistik regresyon modeli test kümesinde %64.1 doğruluk elde etti ve taban çizgisinin (%43.8) belirgin biçimde üzerine çıktı. Sınıf bazlı metrikler (Tablo 4) modelin ev (H) ve deplasman (A) galibiyetlerini iyi ayırdığını, ancak beraberlikleri (D) neredeyse hiç yakalayamadığını gösterir (beraberlik duyarlılığı yalnızca 0.07). Karışıklık matrisi (Şekil 5) bunu görsel olarak doğrular: gerçek beraberlikler çoğunlukla ev ya da deplasman galibiyeti olarak tahmin edilmiştir. Bu, beraberliklerin istatistiksel olarak belirgin bir 'imzaya' sahip olmayan, dengeli maçlar olmasıyla tutarlıdır.

Sınıf	Kesinlik	Duyarlılık	F1	Örnek sayısı
Ev galibiyeti (H)	0.67	0.88	0.76	133
Beraberlik (D)	0.28	0.07	0.12	68
Dep. galibiyeti (A)	0.66	0.71	0.68	103
Genel doğruluk	—	—	0.64	304

Tablo 4. Test kümesi (304 maç) sınıf bazlı performans metrikleri.



Şekil 5. Test kümesi karışıklık matrisi (Doğruluk $\approx$ %64).

Modelin standardize edilmiş katsayıları, bulgularla uyumludur: ev galibiyeti olasılığını en çok artıran özellikler ilk yarı gol farkı (katsayı $\approx +1.13$) ve isabetli şut farkıdır ($\approx +0.92$). Korner farkının katsayısı ev galibiyeti için hafifçe negatiftir (≈ -0.26); bu da S2'deki 'çok korner = üstünlük değildir' gözlemini destekler. Böylece model, korelasyon analiziyle aynı hikâyeyi bağımsız bir yöntemle teyit eder.

5. Sınırlamalar

- Açıklama vs. tahmin: Özellikler maç içi istatistiklerdir ve ancak maç oynanırken oluşur. Bu nedenle model maç öncesi bir tahmin aracı değil, sonucu açıklayan bir modeldir. Gerçek bir öngörü sistemi maç öncesi değişkenler (takım formu, kadro, sakatlıklar, bahis oranları) gerektirir; bu çalışmanın sonuçları bu anlamda betimleyici olarak yorumlanmalıdır.

- Kapsam ve genellenebilirlik: Yalnızca tek lig (Premier Lig) ve dört sezon kullanıldığından bulgular diğer liglere doğrudan genellenemeyebilir; ligler arasında rekabet düzeyi, oyun stili ve ev sahibi avantajının büyüklüğü farklılık gösterebilir.
- Zaman boyutunun göz ardı edilmesi: Maçlar takvim sırasına sahip olmasına rağmen model her maçı bağımsız kabul eder. Takımların form/momentum gibi zamana bağlı etkileri ve sezon içi gelişimleri modele dahil edilmemiştir.
- Beraberlik sınıfı: Beraberlikler doğası gereği modellenmesi zordur; sınıf dengesizliği (test kümesinde yalnızca 68 beraberlik) ve ayırt edici istatistiksel imzanın zayıflığı bu sınıftaki performansı belirgin biçimde düşürür.
- Model kapsamı: Proje süresi gereği kapsamlı hiperparametre optimizasyonu veya çoklu model karşılaştırması yapılmamış, kapsamı dar tutarak tek ve savunulabilir bir model (lojistik regresyon) tercih edilmiştir.

6. Öğrenilenler

- Temizlik analizden önce gelir: Tip dönüşümü, eksik ve aykırı değer kontrolü gibi adımlar sonuçların güvenilirliğini doğrudan belirler. Aykırı değerleri körü körüne silmek yerine (bu projede yüksek şutlu maçlar gibi) bağlamlarını değerlendirmek gerekir.
- Korelasyon nedensellik değildir: Kart–sonuç ilişkisinin negatif çıkması bunun net bir örneğidir; kart, üstünlüğün nedeni değil çoğunlukla geride olmanın sonucudur. Bu, sayısal bir ilişkiyi yorumlarken alan bilgisinin neden gerekli olduğunu gösterir.
- Bağlam istatistikleri değiştirir: Seyircisiz 2020-21 sezonunda ev avantajının kaybolması, sayıların ardındaki gerçek dünya koşullarını (bu örnekte taraftar etkisini) sorgulamanın önemini somut biçimde ortaya koyar.
- Basit model de değerlidir: Yorumlanabilir bir model (lojistik regresyon) bile temayla ilgili anlamlı, savunulabilir içgörüler üretebilir ve korelasyon analiziyle aynı sonuca bağımsız olarak ulaşabilir; karmaşık model her zaman gerekli değildir.
- Tek metrik yanıltır: Bir sınıfın (beraberlik) düşük performansı, genel doğruluğun tek başına yeterli olmadığını ve sınıf bazlı metriklerle karışıklık matrisinin birlikte incelenmesi gerektiğini hatırlatır.
- Tekrarlanabilirlik: Rastgelelik tohumunun (seed) sabitlenmesi ve verinin depoda hazır tutulması, analizin başkalarınca birebir yeniden üretilebilmesini sağlar — bu, güvenilir bir veri bilimi çalışmasının temel gereğidir.

Bu rapor, depodaki notebook/spor_analitigi.ipynb dosyasındaki analizlerin özetidir. Tüm sayısal değerler ve grafikler aynı notebook çalıştırılarak yeniden üretilebilir.